

Machine Learning

SISTEMAS DE APRENDIZAJE AUTOMÁTICO

1. Introducción al aprendizaje automático

Qué es el Machine Learning

El Machine Learning (ML) es la disciplina que permite a un sistema aprender patrones a partir de datos para hacer predicciones o tomar decisiones, sin que un programador escriba explícitamente las reglas de decisión.

Definición clásica de Aprendizaje automático (Tom Mitchell, 1997): un programa aprende de una experiencia *E* con respecto a una tarea *T* y una medida de rendimiento *P*, si su rendimiento en *T*, medido por *P*, mejora con la experiencia *E*.

Ejemplo: filtrar correo spam.

- **Tarea *T*:** clasificar correos como spam / no spam.
- **Medida *P*:** porcentaje de correos clasificados correctamente.
- **Experiencia *E*:** miles de correos ya etiquetados por usuarios.

1.2 Auge del Machine Learning

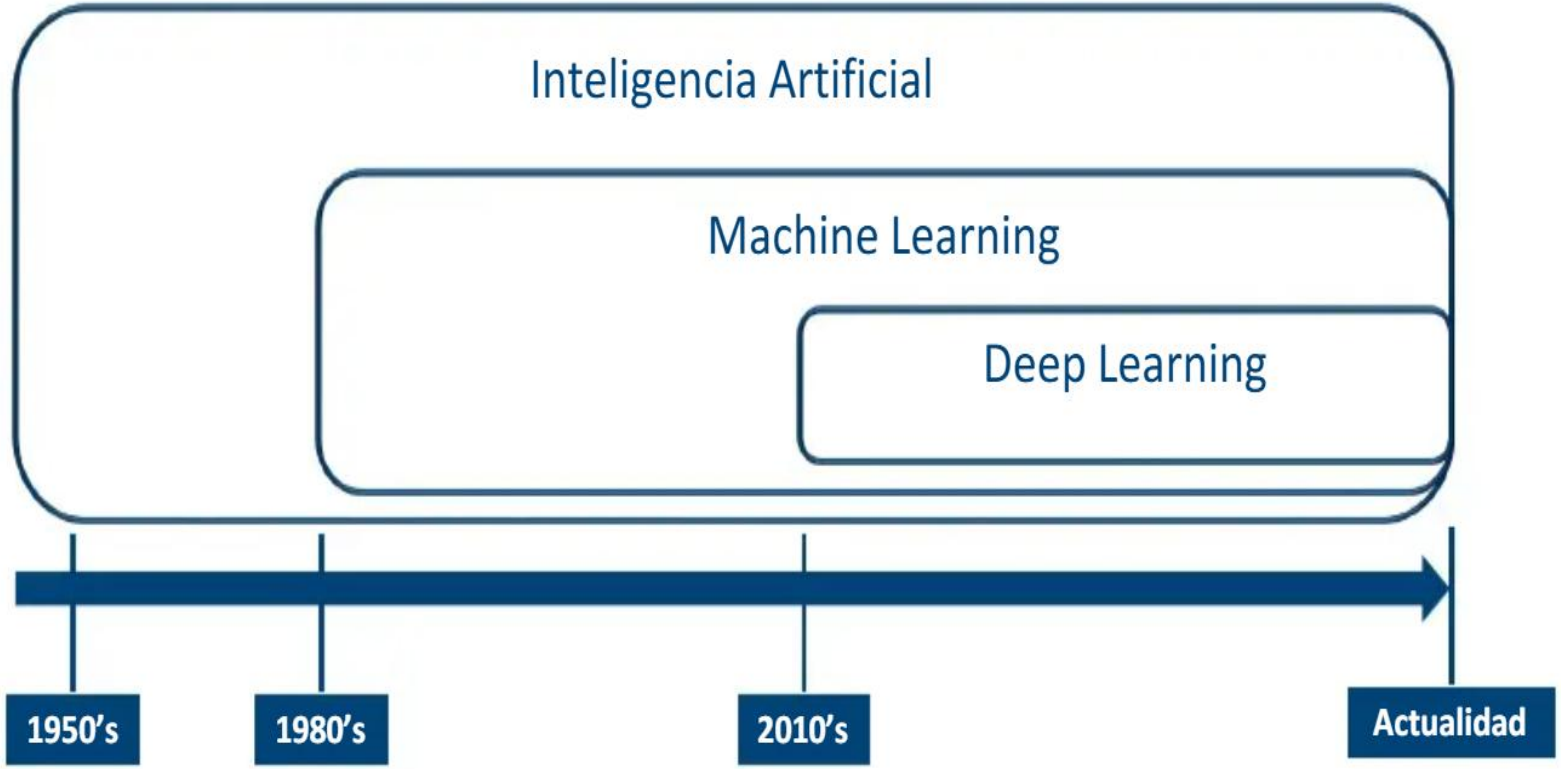
El auge del ML en la última década responde a tres factores convergentes:

- Datos: digitalización masiva (web, sensores, móviles, IoT).
- Cómputo: GPUs, TPUs y cómputo en la nube a bajo coste.
- Algoritmos: mejoras en redes profundas, optimización y frameworks.

1.3 Relación con IA, Big Data y Ciencia de Datos

- Inteligencia Artificial (IA): campo más amplio; incluye reglas, planificación, razonamiento, robótica.
- Machine Learning: subcampo de la IA centrado en aprender de datos.
- Deep Learning: subcampo del ML basado en redes neuronales profundas.
- Ciencia de Datos: disciplina aplicada que integra ML, estadística, ingeniería y conocimiento del negocio.
- Big Data: tecnologías para almacenar y procesar datos a gran escala (volumen, velocidad, variedad, veracidad, valor).

Contexto



Machine Learning:

- Aprendizaje supervisado
- Aprendizaje no supervisado
- Aprendizaje por refuerzo
- Deep Learning

1.4 Aplicaciones de Machine Learning

Industria y mantenimiento predictivo → Los modelos utilizan vibraciones, temperatura, presión y registros de funcionamiento para estimar la probabilidad de avería de una máquina.

Finanzas y detección de fraude → Se analizan transacciones para identificar operaciones anómalas o estimar el riesgo de fraude.

Comercio y logística → Se predice la demanda, se optimizan inventarios y se estiman tiempos de entrega.

Sanidad → Se procesan imágenes médicas, se analizan señales fisiológicas y se construyen herramientas de apoyo al diagnóstico. Su uso exige validación clínica y supervisión adecuada.

Agricultura inteligente → Se estiman rendimientos, se identifican enfermedades en cultivos y se optimiza el riego.

1.5 Ventajas y limitaciones

Ventajas:

- Permite identificar relaciones complejas entre variables.
- Automatiza tareas repetitivas de predicción y clasificación.
- Puede mejorar cuando se dispone de datos representativos y de calidad.
- Facilita el análisis de grandes volúmenes de información.
- Puede adaptarse a diferentes dominios mediante algoritmos y modelos distintos.

Limitaciones

- Necesita datos adecuados para el problema.
- Puede aprender sesgos presentes en los datos históricos.
- No garantiza que las relaciones aprendidas sean causales.
- Puede fallar cuando cambian las condiciones del entorno.
- Los modelos complejos pueden ser difíciles de interpretar.
- Su entrenamiento, despliegue y mantenimiento tienen costes.
- Una elevada precisión estadística no garantiza que el sistema sea útil, justo o seguro.

1.6 No utilizar Machine Learning

No todos los problemas necesitan un modelo de aprendizaje automático.

Puede ser preferible un programa convencional cuando:

- Las reglas son claras, estables y fáciles de mantener.
- El cálculo es determinista y tiene una solución conocida.
- No existen datos suficientes para entrenar y evaluar.
- El coste de los errores supera el beneficio esperado.
- La explicación de cada decisión debe ser completamente determinista y el modelo elegido no permite ofrecer garantías adecuadas.

Por ejemplo, para calcular el importe de una factura a partir de cantidades, precios e impuestos, normalmente es mejor aplicar fórmulas y reglas contables que entrenar un modelo predictivo.

2. Conceptos Fundamentales

Concepto	Definición
Dataset	Conjunto organizado de datos utilizado en el proyecto.
Instancia o muestra	Un elemento individual del conjunto de datos.
Característica (feature)	Variable que describe una muestra y sirve como entrada del modelo.
Etiqueta (label)	Resultado conocido que se desea predecir en aprendizaje supervisado.
Algoritmo	Procedimiento que permite aprender a partir de los datos.
Modelo	Función o estructura resultante del entrenamiento.
Entrenamiento	Proceso de ajustar el modelo utilizando datos.
Predicción	Resultado que produce un modelo para una nueva entrada.
Parámetro	Valor interno que el algoritmo ajusta durante el entrenamiento.
Hiperparámetro	Configuración establecida antes o durante la selección del entrenamiento.
Inferencia	Uso de un modelo entrenado para obtener predicciones.
Generalización	Capacidad de funcionar correctamente con datos nuevos.

3. Tipos de aprendizaje

Aprendizaje supervisado:

Se dispone de datos etiquetados: para cada entrada x conocemos la salida correcta y.

El aprendizaje supervisado utiliza datos de entrenamiento que incluyen las entradas y sus resultados esperados. El algoritmo busca una función capaz de estimar la salida a partir de las entradas. Los dos grandes tipos de problemas supervisados son la regresión y la clasificación:

- Regresión: la salida es continua (precio de una vivienda, temperatura).
- Clasificación: la salida es una categoría (spam/no spam, especie de flor).

Algoritmos típicos: regresión lineal y logística, árboles de decisión, Random Forest, Gradient Boosting, SVM, k-NN, redes neuronales.

Regresión

La regresión se utiliza cuando se desea predecir una magnitud numérica.

Ejemplos:

- Precio de una vivienda.
- Consumo energético de una instalación.
- Demanda de un producto.
- Tiempo de reparación de una máquina.
- Temperatura prevista.

Clasificación

La clasificación se utiliza para asignar una categoría a una muestra.

Ejemplos:

- Correo spam o no spam.
- Cliente que abandona o permanece.
- Imagen de gato, perro u otra categoría.
- Transacción legítima o fraudulenta.
- Avería de tipo A, B o C.

La clasificación puede ser:

- **Binaria:** dos clases.
- **Multiclase:** tres o más clases mutuamente excluyentes.
- **Multietiqueta:** una muestra puede pertenecer simultáneamente a varias categorías.

Ejemplo práctico de características y etiquetas

Imaginemos un conjunto de datos sobre viviendas:

Superficie (m^2)	Habitaciones	Antigüedad (años)	Precio (€)
70	2	15	145.000
90	3	10	190.000
120	4	5	275.000
65	2	30	120.000

Ejemplo

Si el objetivo consiste en predecir el precio:

- Las características son la superficie, el número de habitaciones y la antigüedad.
- La etiqueta es el precio.
- Cada fila constituye una muestra.
- El modelo aprende una relación entre las características y el precio.

El precio es una variable numérica continua. Por tanto, **el problema es de regresión.**

Si, por el contrario, quisiéramos predecir si una vivienda se venderá en menos de 30 días, la etiqueta podría ser **sí o no.** En ese caso tendríamos **un problema de clasificación.**

Interpretación del aprendizaje

1. Se toma una muestra del conjunto de entrenamiento.
2. El modelo produce una predicción.
3. Se compara la predicción con el resultado real.
4. La función de pérdida calcula el error.
5. El algoritmo modifica los parámetros, cuando corresponde.
6. Se repite el procedimiento para mejorar el modelo.

Ejemplo numérico sencillo:

Un modelo predice que una vivienda vale 200.000 €, pero su precio real es 190.000 €.

El error absoluto es:

$$| 190000 - 200000 | = 10000$$

El error absoluto es de 10.000 €.

Si el modelo predijera 160.000 €, el error absoluto sería de 30.000 €. Según esta medida, la primera predicción es mejor.

Sin embargo, evaluar un modelo real exige más que analizar un ejemplo: hay que comprobar su rendimiento en un conjunto representativo de datos que no haya utilizado para aprender.

3. Tipos de aprendizaje II

Aprendizaje no supervisado

No se dispone necesariamente de una etiqueta objetivo conocida. El propósito es encontrar estructura en los datos.

Los principales tipos de tareas incluyen:

- Agrupamiento o clustering: descubrir grupos de muestras similares. Formar grupos de observaciones parecidas, como segmentos de clientes.
- Reducción de dimensionalidad: representar los datos mediante menos variables o componentes conservando parte de la información relevante.
- Detección de anomalías: identificar observaciones que se apartan del comportamiento habitual, es decir, poco habituales respecto al patrón normal.

Ejemplo de segmentación de clientes

Una empresa dispone de información sobre compras, frecuencia de visita y gasto medio. No tiene etiquetas que indiquen el tipo de cliente.

Un algoritmo de clustering puede identificar grupos como:

- Clientes frecuentes con gasto elevado.
- Clientes ocasionales con gasto reducido.
- Clientes que compran mucho en campañas concretas.

Estos grupos son patrones estadísticos, no necesariamente categorías reales o definitivas. La empresa debe interpretarlos y comprobar si son útiles.

3. Tipos de aprendizaje III

Aprendizaje semisupervisado y autosupervisado

En el aprendizaje semisupervisado se combina una cantidad limitada de datos etiquetados con una cantidad mayor sin etiquetar. En el autosupervisado, el sistema genera objetivos de aprendizaje a partir de los propios datos; por ejemplo, ocultar partes de un texto y aprender a predecirlas. Estas técnicas son importantes cuando etiquetar datos resulta caro.

3. Tipos de aprendizaje IV

Aprendizaje por refuerzo

Un agente interactúa con un entorno, ejecuta acciones y recibe recompensas o penalizaciones. Aprende una política para maximizar la recompensa acumulada. Se aplica, por ejemplo, a robótica, control y ciertos problemas de planificación. A diferencia del aprendizaje supervisado clásico, no se dispone necesariamente de una etiqueta correcta para cada situación.

Resumen elección de tipos de aprendizaje

Pregunta	Enfoque inicial	Ejemplo
¿Tengo ejemplos con respuesta conocida?	Supervisado	Predecir impago histórico
¿Quiero descubrir grupos?	No supervisado	Segmentación de clientes
¿Tengo pocas etiquetas y muchos datos sin etiquetar?	Semisupervisado/autosupervisado	Clasificar imágenes con pocas etiquetas
¿Un agente aprende mediante acciones y recompensas?	Por refuerzo	Control de un robot

Autoevaluación

- Explica con tus palabras la diferencia entre programación tradicional y aprendizaje automático.
- En un sistema que predice el consumo eléctrico de una vivienda, identifica las muestras, las características y la etiqueta.
- Clasifica estos problemas como regresión, clasificación o agrupamiento:
  - Predecir el precio de un vehículo.
  - Determinar si una transacción es fraudulenta.
  - Agrupar clientes según sus hábitos de compra.
  - Estimar el tiempo de entrega de un paquete.
- Propón un caso en el que una solución basada en reglas sea preferible a un modelo de Machine Learning.
- Explica por qué un modelo que funciona bien con los datos de entrenamiento puede fallar con datos nuevos.

4. Aprendizaje supervisado, algoritmos

La regresión lineal es un algoritmo de aprendizaje supervisado que modela la relación matemática entre una variable dependiente (lo que se quiere predecir) y una o más variables independientes (las características de entrada) mediante una línea recta o un plano

La regresión logística es un algoritmo de aprendizaje supervisado que se utiliza principalmente para resolver problemas de clasificación (predecir categorías o resultados discretos, como sí/no o 0/1) en lugar de valores continuos

4. Aprendizaje supervisado, algoritmos II

Árboles de decisión, divide repetidamente los datos mediante reglas sobre variables. En clasificación puede buscar divisiones que reduzcan la impureza; en regresión, reducir la variabilidad del objetivo.

Random forest, entrena muchos árboles sobre muestras aleatorias de los datos y considera subconjuntos aleatorios de variables en las divisiones.

Gradient boosting, los métodos de boosting construyen una secuencia de modelos débiles; cada nueva etapa intenta corregir errores residuales de las anteriores.

K vecinos más próximos (k-NN), para predecir una observación, k-NN busca los k ejemplos de entrenamiento más cercanos según una métrica de distancia.

4. Aprendizaje supervisado, algoritmos III

Máquinas de Vectores de Soperte, las SVM pueden funcionar bien en conjuntos pequeños o medianos con variables adecuadas, pero el ajuste de parámetros puede ser delicado y el entrenamiento puede resultar costoso en conjuntos muy grandes.

Naive Bayes, la suposición suele ser simplificadora, pero el método es rápido y puede funcionar bien en clasificación de texto, filtrado de spam y tareas con muchas variables.

4. Aprendizaje supervisado, algoritmos IV

Algoritmo	Ventajas habituales	Limitaciones habituales
Regresión lineal/logística	Rápida, interpretable, buena línea base	Supuestos limitados sin transformaciones
Árbol de decisión	Explicable, captura no linealidad	Puede sobreajustarse
Random Forest	Robusto, buen rendimiento general	Menos transparente, modelo más pesado
Gradient Boosting	Muy competitivo en datos tabulares	Más parámetros y ajuste cuidadoso
k-NN	Intuitivo, poca fase de entrenamiento	Inferencia costosa, sensible a escala
SVM	Eficaces en ciertos conjuntos de datos	Escalabilidad y ajuste de kernel
Naive Bayes	Muy rápido, útil en texto	Supuesto de independencia fuerte

5. Aprendizaje no supervisado, algoritmos

Clustering con k-means, k-means divide los datos en k grupos, asignando cada observación al centroide más cercano y actualizando después los centroides. El proceso se repite hasta estabilizarse.

Clustering jerárquico, el agrupamiento jerárquico crea una estructura de grupos anidados.

DBSCAN, identifica regiones densas separadas por regiones de baja densidad.

Evaluar agrupamientos, un agrupamiento matemáticamente compacto no garantiza segmentos útiles para una decisión real.

Detección de anomalías, una anomalía es una observación que se aparta del comportamiento esperado. Puede ser un fraude, una avería, un error de sensor o un evento legítimo poco frecuente.

6. Sobreajuste, subajuste y regularización

Subajuste (underfitting), el modelo es demasiado simple para capturar la estructura de los datos. Presenta errores elevados tanto en entrenamiento como en validación. Puede ayudar utilizar mejores variables, un modelo más flexible o reducir una regularización excesiva.

Sobreajuste (overfitting), el modelo aprende detalles y ruido específicos del conjunto de entrenamiento y no generaliza bien. Suele observarse un rendimiento excelente en entrenamiento y claramente peor en validación.

Regularización, la regularización penaliza modelos excesivamente complejos. El parámetro de regularización controla la intensidad del castigo y debe seleccionarse mediante validación.

FIN